1 Introdução

1.1 Motivação e contexto

Com a expansão do uso de dados em processos analíticos, manter *pipelines* de ingestão em funcionamento passou a ocupar uma parte importante do trabalho de engenharia de dados (Foidl et al., 2024). Quando esses dados são extraídos de uma fonte externa, parte desse funcionamento fica sujeita à estrutura publicada pelo produtor. O consumidor não controla essa estrutura, embora dependa dela para executar consultas, transformações e outros procedimentos. No contexto dos dados governamentais abertos, essa relação também envolve a confiança na instituição responsável pela disponibilização dos dados (Zainal; Abdul Rahim; Mior Nazri, 2024). A avaliação da qualidade também considera a adequação dos dados ao uso pretendido (Syed et al., 2023).

A estrutura esperada dos dados constitui o *schema*, que inclui colunas, tipos e restrições. Sua modificação pode envolver a adição, a remoção, a renomeação ou a alteração de componentes e atingir consultas, visões, procedimentos e código que dependem deles (Brahmia; Grandi; Oliboni, 2024). Problemas de tipo, representação, caracteres e compatibilidade também interferem no processamento (Foidl et al., 2024).

Um *data contract*, entendido neste trabalho como um acordo formal entre produtor e consumidor, pode estabelecer expectativas sobre a estrutura e o significado dos dados, obrigações e políticas de descontinuação (Open Data Mesh Initiative, 2025). Sem esse acordo, o consumidor precisa verificar os dados recebidos e decidir se eles continuam compatíveis com o processamento.

No setor público, regras e métricas são usadas para avaliar a qualidade dos dados. Entre essas verificações, a validação de *schema* permite examinar a integridade estrutural e identificar anomalias (Silva et al., 2025). O cenário analisado utiliza dados do Cadastro Nacional de Estabelecimentos de Saúde (CNES), disponibilizados pelo Departamento de Informática do Sistema Único de Saúde (DATASUS), cuja documentação descreve os layouts dos arquivos de disseminação (Brasil, 2017). O CNES publica informes sobre atualizações do sistema e alterações em arquivos (Brasil. Ministério da Saúde. Departamento de Informática do SUS, 2026).

Neste experimento, entretanto, a validação será realizada a partir dos dados recebidos, sem utilizar esses informes como entrada para a detecção de mudanças. Logo, a motivação desta pesquisa está na necessidade de identificar alterações nos dados consumidos antes que elas comprometam as etapas seguintes do processamento.

1.2 Problema de pesquisa

Sem uma garantia formal de versionamento ou comunicação de mudanças, os dados de uma fonte externa podem chegar à *pipeline* com uma estrutura diferente da esperada. Essa mudança pode provocar uma falha durante o processamento ou permitir que dados incompatíveis avancem no fluxo. O problema desta pesquisa é determinar até que ponto ferramentas de qualidade de dados conseguem detectar e bloquear essas incompatibilidades antes que alcancem as etapas seguintes, sem interromper o processamento de dados que continuam válidos.

Uma incompatibilidade não detectada permite que dados inadequados avancem pela *pipeline*. Um bloqueio indevido interrompe o processamento de um lote que continua válido. Para o consumidor, a dificuldade está em saber quais mudanças cada ferramenta reconhece e se o bloqueio ocorre apenas quando a entrada viola as condições definidas.

A pesquisa será orientada pela seguinte pergunta:

Em uma *pipeline batch* de ingestão de dados do CNES, em que medida Great Expectations, Pandera, Frictionless e Soda Core detectam e bloqueiam mudanças estruturais predefinidas, quando configuradas segundo uma mesma política de aceitação, considerando cobertura de detecção por tipo de mudança, falsos bloqueios, tempo de configuração e tempo de execução?

1.3 Justificativa

Para escolher uma ferramenta, o consumidor precisa saber quais mudanças ela detecta, se consegue impedir o avanço de entradas incompatíveis e com que frequência bloqueia dados válidos. A lista de funcionalidades declaradas não basta para estabelecer como as ferramentas se comportam diante dos mesmos casos. O estudo do tema exige, portanto, observar os resultados produzidos em condições comparáveis.

Pesquisas anteriores mostram que mudanças entre versões de bases públicas podem comprometer análises posteriores (Yamanaka et al., 2024) e que regras definidas pelo consumidor revelam inconsistências em dados governamentais (Oliveira et al., 2023). Também indicam que verificações semelhantes recebem nomes e formas de configuração diferentes (Papastergios; Ehrlinger; Gounaris, 2026) e que ferramentas de qualidade de dados já foram comparadas por meio de uma base comum e de casos de teste associados a requisitos definidos (Ehrlinger; Wöß, 2022). Entre os trabalhos incluídos na revisão bibliográfica deste estudo, não foi identificada uma avaliação que reúna Great Expectations, Pandera, Frictionless e Soda Core sob as mesmas entradas, a mesma política de aceitação e a mesma definição de bloqueio.

A adoção de condições comuns reduz a influência de diferenças entre regras, dados e critérios de sucesso sobre os resultados. A pesquisa poderá mostrar a cobertura de cada ferramenta por tipo de mudança, os bloqueios indevidos, as incompatibilidades não detectadas e os tempos de configuração e execução. Essas medidas poderão apoiar a escolha de uma ferramenta segundo as mudanças que ela reconhece, os erros que produz e o tempo exigido para configurá-la e executá-la.

1.4 Objetivos

1.4.1 Objetivo geral

Avaliar comparativamente a capacidade de Great Expectations, Pandera, Frictionless e Soda Core para detectar e bloquear mudanças estruturais predefinidas em uma *pipeline batch* de ingestão de dados do CNES, sob uma mesma política de aceitação, considerando a cobertura por tipo de mudança, os falsos bloqueios e os tempos de configuração e execução.

1.4.2 Objetivos específicos

- Definir uma política comum de aceitação e cenários com adição, remoção, renomeação e reordenação de colunas, alteração de tipo, nulidade, delimitador e *encoding*;
- configurar e integrar as quatro ferramentas à mesma *pipeline batch*;
- executar casos provenientes de versões históricas do CNES e de mutações sintéticas controladas;
- medir a cobertura de detecção por tipo de mudança, os falsos bloqueios, as falhas não detectadas, a capacidade de interromper a etapa seguinte e os tempos de configuração e execução;
- comparar os resultados e as limitações das ferramentas no cenário estudado.

2 Trabalhos relacionados

2.1 Qualidade e falhas em pipelines de dados

Foidl et al. (2024) investigam os fatores que comprometem a capacidade das *pipelines* em processar dados corretamente e entregá-los com qualidade. Para compreender esses fatores e localizar os problemas relacionados aos dados, o estudo combina uma revisão multivocal da literatura,

entrevistas com oito profissionais de engenharia de dados e análises de *issues* do GitHub e publicações do Stack Overflow. A revisão resultou em uma taxonomia de 41 fatores, distribuídos entre aspectos dos dados, do desenvolvimento, da infraestrutura, do ciclo de vida e do processamento.

Na análise do GitHub, problemas de tipo representaram 33% das 100 *issues* relacionadas a dados identificadas no conjunto final. Essas ocorrências apareceram principalmente nas etapas de limpeza, ingestão e integração. No Stack Overflow, integração e ingestão reuniram 47% dos tópicos discutidos, enquanto questões de compatibilidade formaram uma categoria adicional aos estágios usuais de processamento. Os autores indicam que a taxonomia pode orientar a identificação e a priorização de aspectos que prejudicam a qualidade das *pipelines*.

A pesquisa ajuda a delimitar o que uma estratégia de validação precisa observar, pois tipos, representação, caracteres e compatibilidade interferem na forma como os dados são recebidos e processados. Essa relação apoia a escolha de mudanças estruturais que serão avaliadas no TCC. O alcance do estudo, entretanto, permanece descritivo e genérico: são analisados relatos de desenvolvedores e projetos de software, sem o acompanhamento de versões históricas de uma base pública ou o teste de ferramentas de validação sob alterações controladas. Resta observar como esses problemas aparecem quando uma fonte pública muda sua estrutura ao longo do tempo, situação examinada pelo trabalho seguinte.

2.2 Evolução de schema em dados públicos brasileiros

Yamanaka et al. (2024) aproximam a discussão das mudanças que ocorrem quando uma fonte pública disponibiliza novas versões de seus dados. O estudo examina arquivos anuais do Censo Escolar brasileiro, publicados pelo Ministério da Educação e integrados ao Laboratório de Dados Educacionais. Alterações de nomes, adições e remoções de colunas dificultam a correspondência entre os arquivos e o *schema* mantido pelo sistema. Os autores registram 416 mudanças e mostram que uma associação incorreta pode separar em duas colunas uma informação que apenas mudou de nome, preenchendo anos anteriores com valores nulos e comprometendo análises posteriores.

A pesquisa propõe uma metodologia estatística que compara a distribuição das colunas numéricas de versões consecutivas. São avaliados os testes Kolmogorov-Smirnov, Anderson-Darling, t de Welch e F. As sugestões são confrontadas com um *ground truth* em dois cenários: o *Top 1* considera a primeira coluna indicada, enquanto o *Top 3* verifica se a correspondência correta aparece entre as três primeiras. O teste Kolmogorov-Smirnov obteve acurácia média de 84,7% no *Top 1* e 89,7% no *Top 3* na comparação com o ano anterior. Com o acúmulo dos anos anteriores, a acurácia *Top 1* caiu para 74,4%.

O estudo mostra que a evolução estrutural de uma base pública pode ser examinada por quem integra os dados, sem depender dos nomes das colunas. Para este TCC, isso oferece um cenário próximo ao CNES e exemplos de mudanças capazes de afetar a continuidade de uma *pipeline*. A abordagem, contudo, restringe-se a atributos numéricos, mantém um especialista na escolha entre candidatos e não avalia Great Expectations, Pandera, Frictionless ou Soda Core. Com o problema estrutural delimitado, torna-se necessário compreender como ferramentas de qualidade transformam requisitos de validação e monitoramento em recursos disponíveis ao consumidor.

2.3 Medição e monitoramento por ferramentas de qualidade

Ehrlinger e Wöß (2022) investigam como conceitos de medição e monitoramento de qualidade de dados aparecem nas ferramentas disponíveis. O estudo parte da distância entre as dimensões discutidas na literatura e as funções oferecidas na prática. Sua busca reuniu 667 ferramentas associadas à qualidade de dados. Após a aplicação de critérios de exclusão, 17 foram selecionadas e

13 puderam ser avaliadas, sendo oito comerciais e cinco *open-source*. A análise utiliza um catálogo de 43 requisitos sobre *data profiling*, medição de qualidade e monitoramento contínuo. As ferramentas foram instaladas e examinadas por dois pesquisadores com uma versão do banco Northwind.

A comparação mostrou ampla presença de funções básicas de *data profiling* em uma única coluna, como contagem de valores nulos e identificação de tipos. Recursos envolvendo múltiplas colunas ou descoberta de dependências apareceram com menor frequência. Os autores também não encontraram uma ferramenta que implementasse um conjunto amplo das métricas propostas pela literatura para as principais dimensões de qualidade. Algumas métricas de acurácia dependiam de um conjunto de referência que nem sempre existe. O monitoramento automatizado variou entre as soluções e, nas ferramentas generalistas, apareceu frequentemente como recurso de versões comerciais.

Nesse contexto, o catálogo oferece critérios para avaliar regras de validação e recursos de monitoramento. Essa distinção é pertinente para um consumidor que acompanha uma fonte sem possuir uma base confiável para comparar os dados recebidos. O levantamento, contudo, retrata versões específicas das ferramentas e não inclui Great Expectations, Pandera, Frictionless ou Soda Core entre as soluções avaliadas. Também não testa versões históricas de dados públicos ou mudanças estruturais controladas. A visão geral oferecida pelo *survey* deixa uma questão mais específica: quais verificações estão implementadas nas ferramentas *open-source* atuais e como elas representam requisitos de *schema*?

2.4 Funcionalidades de ferramentas open-source

Papastergios, Ehrlinger e Gounaris (2026) aprofundam a análise das ferramentas *open-source* ao examinar como suas funcionalidades são implementadas. O estudo parte de um problema de terminologia: funções semelhantes recebem nomes diferentes nas ferramentas, enquanto um mesmo termo pode representar operações distintas. Para aproximar essas implementações das dimensões discutidas na literatura, os autores selecionam sete projetos ativos e de uso geral, entre eles Great Expectations e Soda Core. A documentação oficial e o código-fonte são examinados separadamente para cada ferramenta. Em seguida, funcionalidades equivalentes são reunidas, organizadas por finalidade e relacionadas a seis dimensões da ISO/IEC 25012.

O levantamento produz um catálogo de verificações de conformidade, distribuição, volume, cardinalidade, correlação e verificações orientadas a *machine learning*. Entre as funções ligadas ao *schema* estão a conferência do número e da ordem das colunas, a presença de campos esperados, a ausência de campos inesperados e a validação de tipos. Os resultados mostram que nenhuma das sete ferramentas cobre todo o conjunto encontrado. Também indicam que a relação entre uma verificação concreta e uma dimensão de qualidade não é direta: uma mesma função pode contribuir para mais de uma dimensão, e uma dimensão depende de diferentes verificações.

O catálogo contribui para esta pesquisa ao relacionar mudanças estruturais a *checks* que podem ser procurados durante a implementação do experimento. A presença de Great Expectations e Soda Core aproxima o *survey* das ferramentas selecionadas, mas Pandera e Frictionless não fazem parte da análise. O trabalho também não executa um *benchmark* entre as soluções. Sua comparação registra funcionalidades incorporadas, sem medir acurácia de detecção, falsos positivos, custo computacional ou esforço de configuração. Assim, o estudo descreve o que as ferramentas oferecem, mas não demonstra como elas se comportam quando recebem versões alteradas de uma base pública. Essa passagem da capacidade catalogada para o uso em dados governamentais aparece no trabalho seguinte, que seleciona Great Expectations e a aplica em duas situações reais.

2.5 Avaliação de dados governamentais com Great Expectations

Oliveira et al. (2023) analisam a qualidade de dados governamentais de Minas Gerais utilizados em aplicações de licitações e despesas públicas. O problema investigado está nas inconsistências que podem afetar análises posteriores e que não são impedidas pelas restrições de integridade do *data warehouse* empregado. Inicialmente, os autores comparam oito ferramentas *open-source* segundo dez categorias de funcionalidades identificadas em suas documentações. Great Expectations foi a solução que melhor atendeu ao conjunto adotado, com parte das funções disponível de forma nativa e parte dependente de customização. A ferramenta foi então aplicada a dez tabelas reais mantidas em Apache Hive, divididas entre os dois domínios governamentais.

A avaliação combina *expectations* nativas com regras desenvolvidas pelos autores em Python. As verificações tratam de valores nulos, unicidade, tipos, intervalos, expressões regulares e relações entre colunas. As regras customizadas examinam condições próprias do domínio, como a coerência entre valores financeiros e a ordem cronológica de datas. Os resultados apontaram valores fora de intervalos, tipos inconsistentes, duplicidades e violações de regras de negócio. O estudo também propõe o *Table Error Score*, uma medida que considera o tamanho da tabela, a proporção de verificações com falha e o percentual de valores inesperados para ordenar tabelas que exigem inspeção manual (Oliveira et al., 2023).

A aplicação de Great Expectations em dados públicos brasileiros é o cenário mais próximo da pesquisa desenvolvida neste TCC. O trabalho mostra como regras definidas por quem utiliza os dados podem revelar inconsistências sem exigir alterações no sistema produtor. Entretanto, somente Great Expectations é executada nos estudos de caso; as outras ferramentas são comparadas por sua documentação. A pesquisa não acompanha mudanças de *schema* entre versões, não utiliza defeitos estruturais controlados e não mede falsos positivos, falsos negativos, esforço de configuração ou custo computacional.

2.6 Análise comparativa

Tomados em conjunto, os cinco trabalhos abordam partes diferentes do problema investigado. A comparação considera o uso de dados públicos, o tratamento de mudanças estruturais, a presença das ferramentas escolhidas e a forma como os estudos avaliam seus resultados. *Sim* indica atendimento ao critério, *Parcial* corresponde a uma cobertura limitada ou indireta e *Não* indica que o critério está fora do escopo do estudo.

Testes com dados são aplicações de um método ou ferramenta sobre uma base. A comparação ocorre sob condições comuns quando mais de uma solução recebe os mesmos casos e critérios. Para medir a acurácia da detecção, o resultado obtido precisa ser confrontado com uma resposta conhecida. Na cobertura das ferramentas, o atendimento parcial indica que apenas parte das quatro soluções do TCC foi incluída.

Critério	Foidl et al. (2024)	Yamanaka et al. (2024)	Ehrlinger e Wöß (2022)	Papastergios et al. (2026)	Oliveira et al. (2023)
Dados públicos	Não	Sim	Não	Não	Sim
Mudanças estruturais	Parcial	Sim	Parcial	Parcial	Parcial
Cobertura das ferramentas do TCC	Não	Não	Não	Parcial	Parcial
Testes com dados	Não	Sim	Sim	Não	Sim
Comparação sob condições comuns	Não	Sim	Sim	Não	Parcial
Acurácia da detecção	Não	Sim	Não	Não	Não

Tabela 1: Comparação dos trabalhos relacionados segundo os critérios desta pesquisa.

Foidl et al. (2024) identificam tipos, representação e compatibilidade entre os problemas encontrados em *pipelines*, mas não submetem métodos de validação a uma base nem medem a detecção desses problemas. Yamanaka et al. (2024) examinam o passo seguinte: mudanças de colunas entre versões de uma base pública. A comparação de quatro testes estatísticos com um *ground truth* permite medir a acurácia das correspondências. Entre os trabalhos analisados, esse é o único que reúne dados públicos, mudanças estruturais observadas entre versões, comparação sob condições comuns e acurácia da detecção. Seu objeto, contudo, é um método de correspondência de colunas, não as ferramentas selecionadas para este TCC.

Ehrlinger e Wöß (2022) executam casos de *data profiling* sobre uma base comum e comparam as soluções por um catálogo de requisitos, embora o conjunto não inclua as quatro ferramentas deste TCC nem meça a acurácia da detecção de mudanças estruturais. Papastergios, Ehrlinger e Gounaris (2026) incluem Great Expectations e Soda Core, porém deixam de fora Pandera e Frictionless. O trabalho examina documentação e código para catalogar *checks*, sem executar as ferramentas sobre versões alteradas. Oliveira et al. (2023) retomam o contexto dos dados públicos e comparam oito soluções pela documentação, mas aplicam apenas Great Expectations. As falhas de *expectations* e os valores inesperados mostram o resultado das validações, embora não permitam calcular a acurácia da detecção sem um *ground truth*.

Nos cinco trabalhos analisados, o estudo de mudanças estruturais em dados públicos permanece separado da avaliação das ferramentas. Este TCC propõe aproximar essas duas frentes: Great Expectations, Pandera, Frictionless e Soda Core serão configuradas segundo uma mesma política de aceitação e receberão as mesmas alterações em dados do CNES. A comparação permitirá observar quais mudanças cada ferramenta detecta e se cada uma impede que entradas incompatíveis prossigam na *pipeline*.

Referências

BRAHMIA, Zouhaier; GRANDI, Fabio; OLIBONI, Barbara. A Literature Review on Schema Evolution in Databases. **Computing Open**, v. 2, p. 2430001, 2024.

BRASIL. MINISTÉRIO DA SAÚDE. DEPARTAMENTO DE INFORMÁTICA DO SUS. **Disseminação de informações do Sistema de Cadastro Nacional de Estabelecimentos do SUS (CNES): informe técnico 2017-06**. [S. l.]: DATASUS, 2017. Disponível em: <https://rfsaldanha.github.io/sis/assets/cnes/IT_CNES_1706.pdf>. Acesso em: 12 out. 2026.

BRASIL. MINISTÉRIO DA SAÚDE. DEPARTAMENTO DE INFORMÁTICA DO SUS. **CNES: informes**. [S. l.]: DATASUS, 2026. Disponível em: <https://cnes2.datasus.gov.br/Mod_Mensagem_Abertura1.asp>. Acesso em: 12 out. 2026.

EHRLINGER, Lisa; WÖSS, Wolfram. A Survey of Data Quality Measurement and Monitoring Tools. **Frontiers in Big Data**, v. 5, p. 850611, 2022.

FOIDL, Harald *et al.* Data Pipeline Quality: Influencing Factors, Root Causes of Data-related Issues, and Processing Problem Areas for Developers. **Journal of Systems and Software**, v. 207, p. 111855, 2024.

OLIVEIRA, Gabriel P. *et al.* Assessing Data Quality Inconsistencies in Brazilian Governmental Data. **Journal of Information and Data Management**, v. 14, n. 1, 2023.

OPEN DATA MESH INITIATIVE. **Data contract. In: Data Product Descriptor Specification**. [S. l.]: Open Data Mesh Initiative, 2025. Disponível em: <https://dpds.opendatamesh.org/concepts/data--contract/>. Acesso em: 12 out. 2026.

PAPASTERGIOS, Vasileios; EHRLINGER, Lisa; GOUNARIS, Anastasios. Unfolding Data Quality Dimensions in Practice: A Survey. **Journal of Data and Information Quality**, v. 18, n. 1, p. 1–37, 2026.

SILVA, Maria Inês Vale *et al.* Systematic Mapping of Data Quality in the Public Sector: Dimensions, Metrics and Practices. *In:* 2025.

SYED, Rehan *et al.* Digital Health Data Quality Issues: Systematic Review. **Journal of Medical Internet Research**, v. 25, p. e42615, 2023.

YAMANAKA, Muriki G. *et al.* Statistical Validation of Column Matching in the Database Schema Evolution of the Brazilian Public School Census. **arXiv preprint arXiv:2407.09885**, 2024.

ZAINAL, Noor Zalina; ABDUL RAHIM, Noor Hayani; MIOR NAZRI, Mior Nasir. Academic Perspectives on Open Government Data: A Study of Quality, Trust and Intention to Use. **Information Management and Business Review**, v. 16, n. 2(I)S, p. 53–61, 2024.